ECM514 · CIÊNCIA DE DADOS · PROJETO DESAFIO 2026

Detecção e diagnóstico de falhas em rolamentos

O modelo aprendeu o defeito — ou o rolamento?

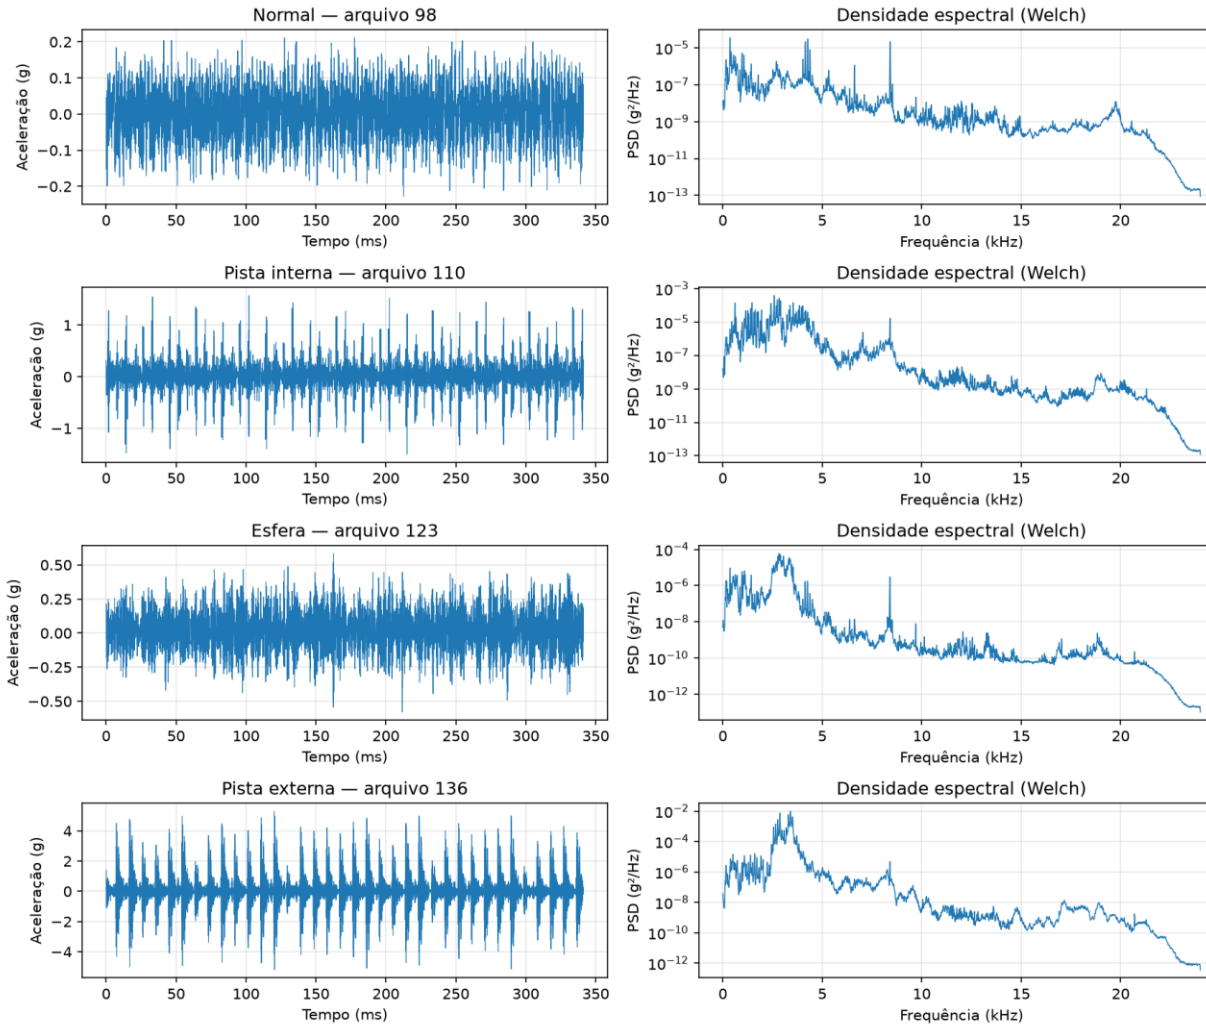
Dataset CWRU · 40 gravações reais a 48 kHz · normal, pista interna, esfera e pista externa

5 detectores de anomalia · 2 classificadores · regra física de envelope

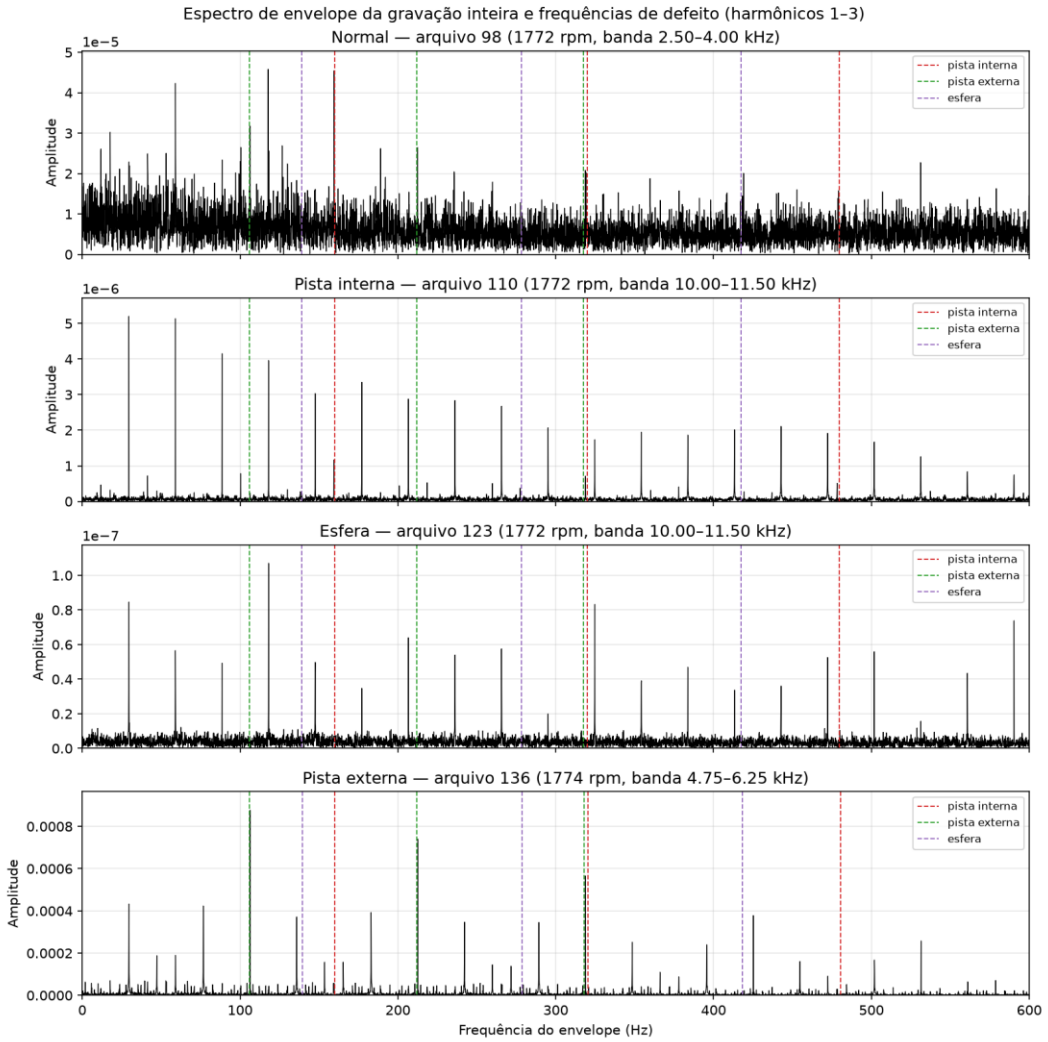
Integrantes: Nome Sobrenome (RA) · Nome Sobrenome (RA) · Nome Sobrenome (RA)

Vibração real de uma bancada com defeitos conhecidos

- Motor de 2 HP, rolamento SKF 6205, acelerômetro no lado do acionamento
- Defeitos usinados por eletroerosão: 0,007", 0,014" e 0,021"
- Cargas de 0 a 3 HP (≈ 1797 a 1720 rpm)
- 4 gravações normais + 36 com falha = 995 janelas de 0,34 s
- **Todas a 48 kHz — a mesma taxa do normal, sem reamostragem**
- SHA-256 conferido em cada arquivo; nenhum dado sintético



Análise de envelope: procurar a frequência do defeito



- Cada impacto excita uma ressonância; o envelope revela o ritmo dos impactos
- Banda escolhida pela curtose espectral, sem usar rótulos
- Frequências da geometria do rolamento: pista interna 160 Hz, pista externa 106 Hz, esfera 139 Hz (1772 rpm)
- **Pista externa: picos nítidos em 106, 212 e 318 Hz**
- **Pista interna: pico em 160 Hz modulado pela rotação do eixo**
- **Esfera: sem pico dominante — o caso difícil da literatura**
- 23 atributos por janela: amplitude, forma de onda, espectro e envelope

Testar o que o modelo nunca viu

DETECÇÃO (treino só com normal)

- Curtose do envelope, Mahalanobis, Isolation Forest, One-Class SVM e autoencoder
- Limiar no percentil 99 de normais fora da amostra

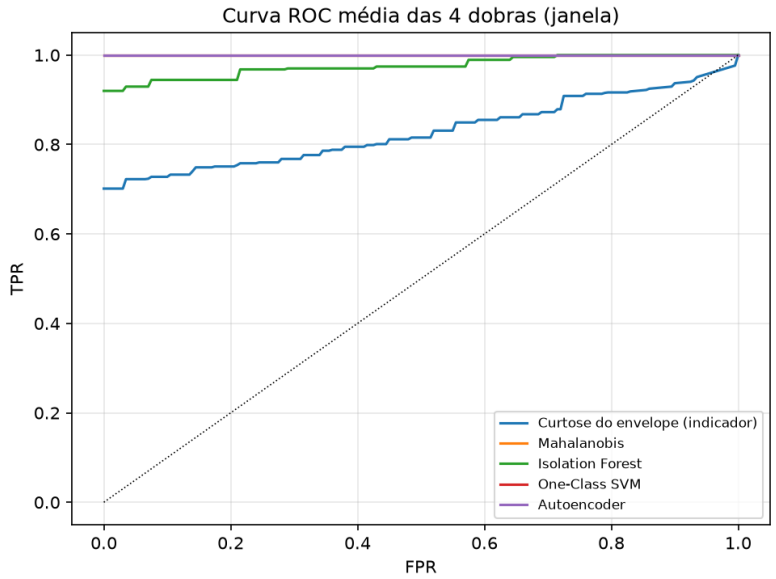
DIAGNÓSTICO (4 classes)

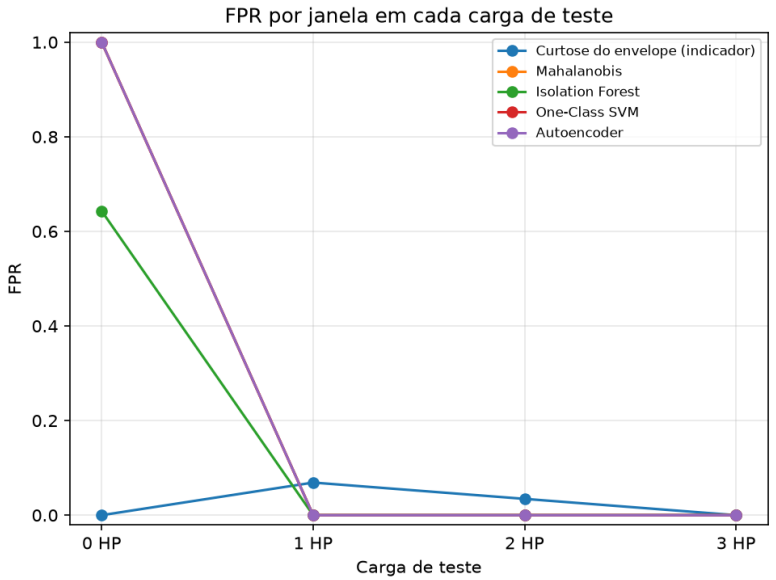
- Random Forest e SVM RBF, hiperparâmetros por validação interna
- Regra física: vence o maior pico de envelope
- Baseline: sempre a classe majoritária

Divisão sempre por gravação inteira

- Carga não vista: treino com 3 cargas, teste na 4ª (4 dobras)
- Diâmetro não visto: treino com 2 tamanhos de defeito, teste no 3º (3 dobras)
- **O segundo teste pergunta: o modelo reconhece o tipo de defeito num rolamento novo?**

Os escores separam; o limiar não se transfere





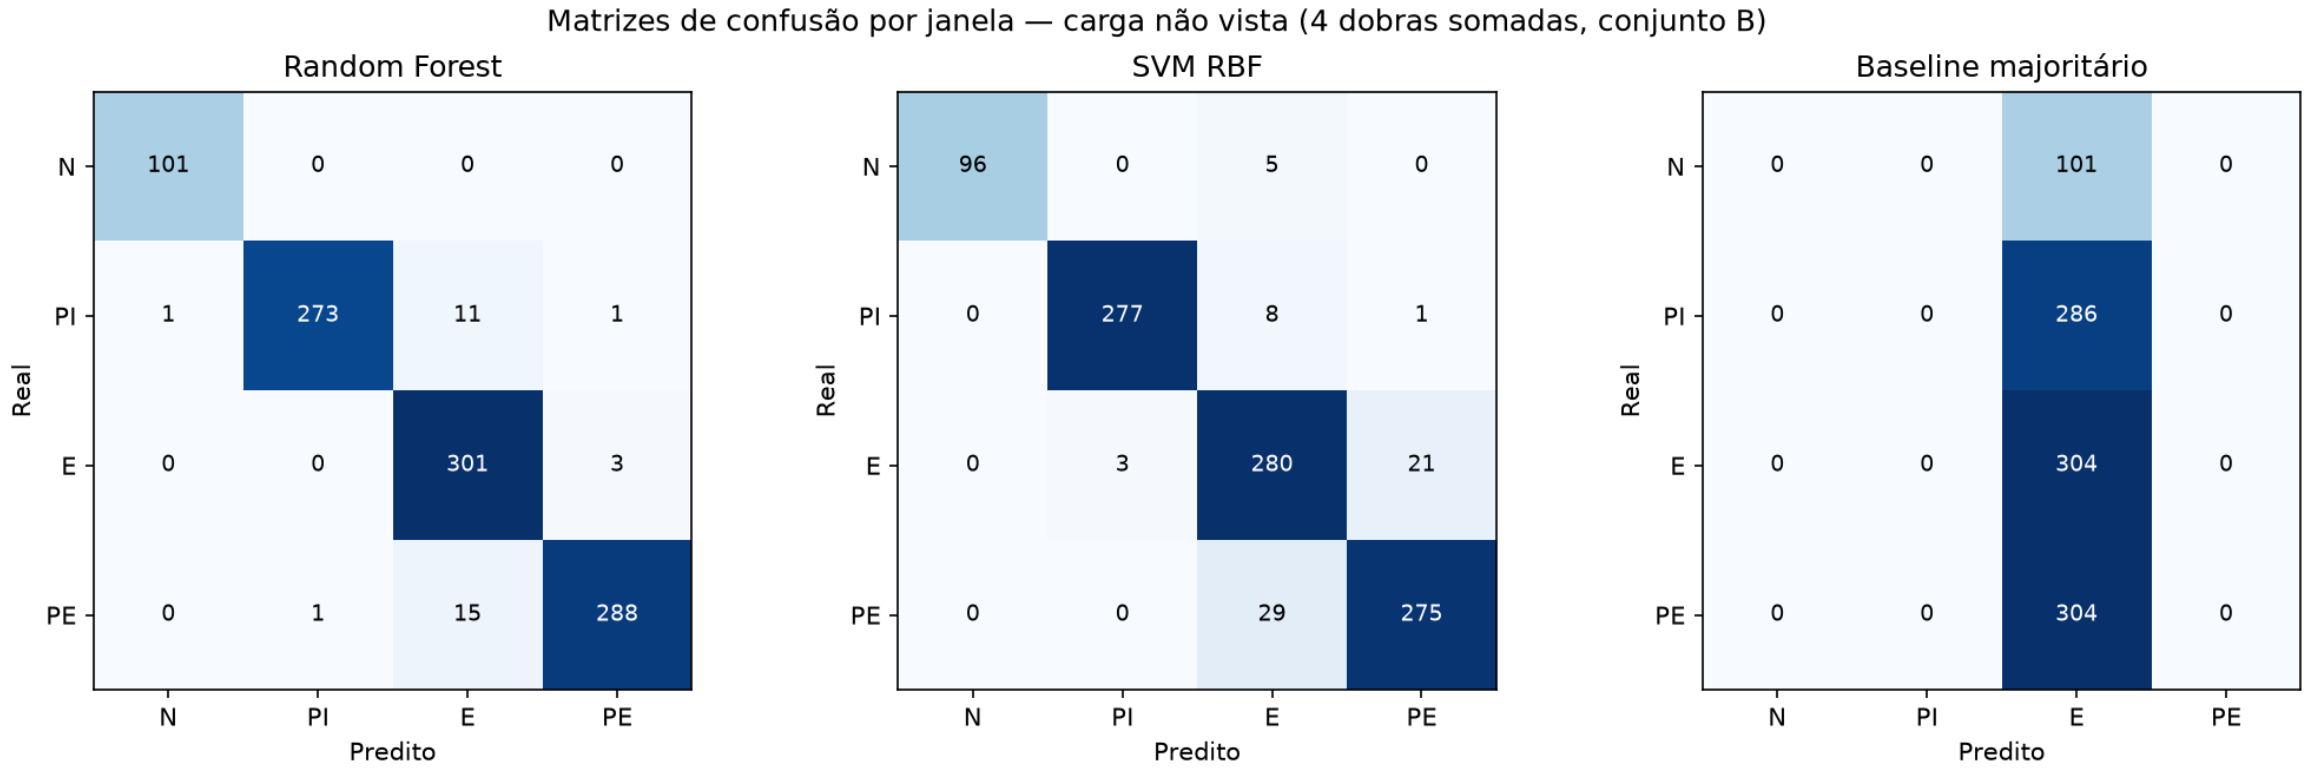
ROC-AUC de 0,975 a 1,000

- Com carga não vista: Isolation Forest TPR 81%, FPR 9%
- O normal de 0 HP dispara alarme em 64–100% das janelas
- Só 4 gravações normais: impossível calibrar entre cargas

Com referência normal em cada carga:

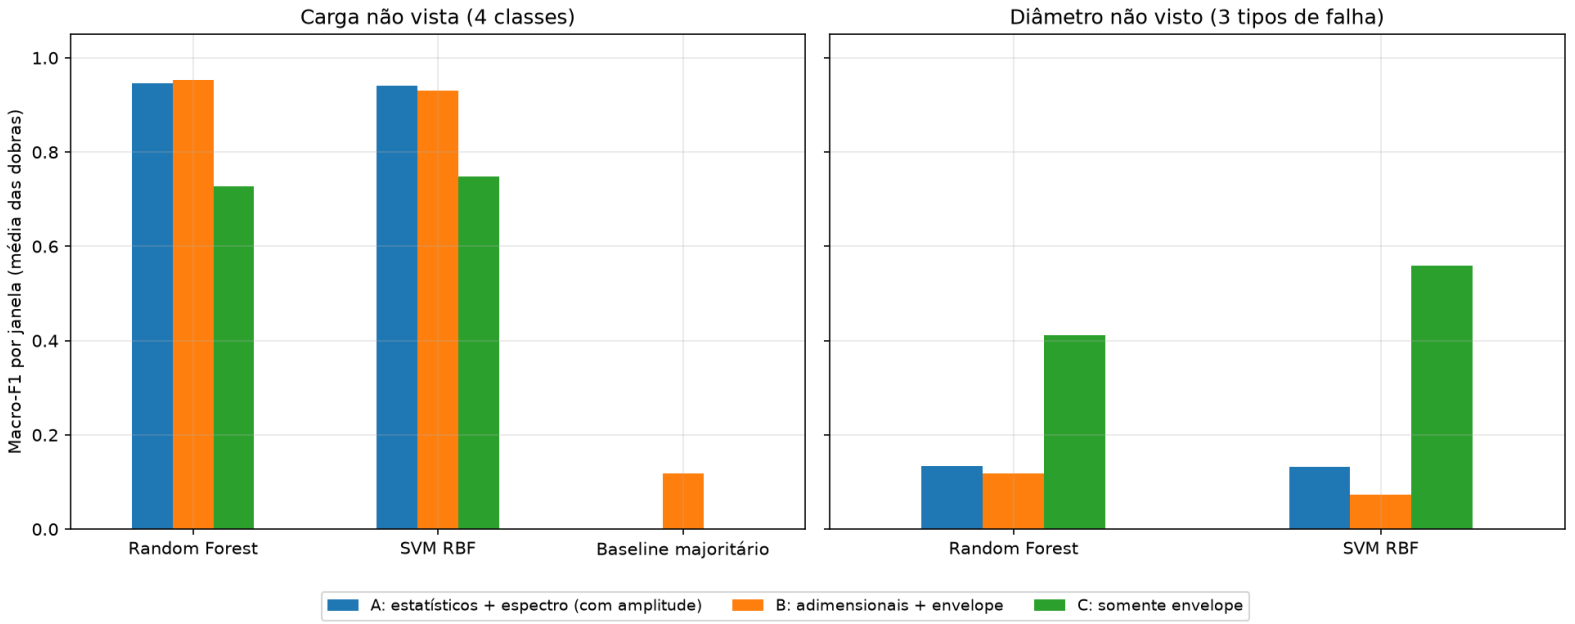
Mahalanobis — TPR 100%, FPR 0%

Random Forest acerta 96,8% das janelas



Random Forest: macro-F1 0,95 · SVM: 0,93 · baseline: 0,12 — por gravação, 90–92,5% de acerto. Erros concentrados em 0 HP e no diâmetro de 0,014".

Com defeito de tamanho novo, os modelos estatísticos colapsam



- Atributos estatísticos: macro-F1 ≤ 0,13 — abaixo do acaso (0,33)
- Todo o diâmetro novo vai para uma única classe
- Só envelope: 0,41–0,56
- **Regra física por gravação: 69% de acerto**

Os 95% com carga nova vêm, em boa parte, de reconhecer o rolamento — não o tipo de defeito.

Alta acurácia não basta: é preciso perguntar o que foi aprendido

- Detectar é fácil com uma referência normal local; difícil sem ela
- ML diagnostica bem um rolamento conhecido em outra carga
- Para um defeito novo, a física do rolamento generaliza melhor
- Esfera continua sendo o caso mais difícil
- Próximos passos: mais referências normais, teste com rolamento novo, Paderborn e falhas naturais

Limitações

- 4 gravações normais
- Defeitos induzidos, uma bancada
- Janelas correlacionadas
- Uso de IA (ChatGPT/Codex e Claude) declarado no relatório

github.com/rodrigo-faltz/CD2026-S2 · notebook, dados, relatório e referências